

CEUB — Centro Universitário de Brasília

Disciplina: Business Intelligence — Turma A

Prof. José Antônio de Paiva Júnior

PROJETO FINAL

Data Warehouse de Recursos Humanos com PostgreSQL e Power BI

Grupo:

Gabriel Francisco - 22408417

Pedro Vargas - 22404088

Pedro Rebello - 22405550

Brasília — junho de 2026

1. Tema escolhido

O tema do projeto é a análise do quadro de Recursos Humanos de uma organização de grande porte. O objetivo é transformar uma base bruta de 1 milhão de registros de funcionários em informação acionável para três perfis de uso: o nível operacional (próprio funcionário, com acesso restrito aos seus dados básicos), o nível tático (equipe de RH, com acesso a salários e indicadores agregados) e o nível estratégico (diretoria, com acesso completo para tomada de decisão sobre folha, demografia e distribuição geográfica).

O Data Warehouse construído permite responder perguntas como: qual a composição demográfica do quadro? Onde estão concentradas as maiores folhas salariais? Como as admissões evoluíram ao longo do tempo? Existem disparidades salariais entre gêneros ou faixas etárias? Quais estados oferecem os maiores e menores salários médios?

2. Fonte dos dados

O dataset utilizado é o Hr1m.csv, base pública disponibilizada na plataforma Kaggle. Trata-se de uma amostra de 1.000.000 (um milhão) de registros de funcionários nos Estados Unidos, com 37 colunas que cobrem identificação pessoal, dados de contato, informações de nascimento, dados de admissão (data, ano, trimestre, dia da semana), dados profissionais (salário, percentual do último aumento, tempo de empresa) e localização (cidade, condado, estado, região, CEP).

A escolha por dados reais (e não fictícios) atende ao requisito obrigatório do enunciado e ao mesmo tempo oferece volume e variedade suficientes para um modelo dimensional não trivial.

Fonte original: <https://www.kaggle.com/datasets/> — arquivo Hr1m.csv (≈ 265 MB).

3. Problema de negócio

Em empresas com dezenas de milhares de colaboradores espalhados por dezenas de estados, a área de Recursos Humanos enfrenta o desafio recorrente de transformar dados transacionais (cadastros, folhas de pagamento, históricos de admissão) em indicadores estratégicos consumíveis pela diretoria. Esses dados costumam estar dispersos em sistemas operacionais, com formatos inconsistentes, tipos de dados em texto e sem nenhuma estrutura analítica.

O problema central que este projeto resolve é justamente esse: como construir uma plataforma analítica que (i) absorva os dados brutos sem perda, (ii) os trate e organize em um modelo dimensional, (iii) sirva camadas otimizadas para diferentes perfis de usuário e (iv) entregue um dashboard que comunique os indicadores principais de forma clara.

Como subproduto, o projeto também responde a perguntas analíticas concretas:

- Existe disparidade salarial entre gêneros, controlando por faixa etária e por estado?
- Em quais regiões dos Estados Unidos a folha total é maior, e isso é explicado pelo número de funcionários ou pelo salário médio?
- Como o volume de admissões evoluiu ao longo dos anos? Há sazonalidade clara entre trimestres?
- Qual a relação entre tempo de empresa e percentual do último aumento?

4. Modelo dimensional

O Data Warehouse foi construído seguindo o paradigma estrela, com uma tabela de fato central (fato_rh) cercada por sete dimensões. Para localização geográfica, optou-se por aplicar snowflake, normalizando a hierarquia em três níveis (localização → estado → país).




Figura 1 — Modelo estrela do Data Warehouse

4.1 Granularidade da fato

A tabela fato_rh tem como granularidade uma linha por funcionário, representando o estado atual de cada colaborador no momento da carga (snapshot de admissão). Esta granularidade é a mais fina possível dado o dataset disponível e permite agregações livres por qualquer combinação de dimensões.

4.2 Composição do modelo

A tabela abaixo descreve cada componente do modelo:

Tipo	Tabela	Descrição / Granularidade
Fato	fato_rh	1 linha por funcionário (snapshot de admissão). Métricas: salário, peso, idade, tempo de empresa, % último aumento.
Dimensão	dim_funcionario	Atributos pessoais do funcionário (nome, e-mail, SSN, prefixo).
Dimensão	dim_tempo	Calendário enriquecido (ano, semestre, trimestre, mês, nome do mês, dia, dia da semana, flag de fim de semana). Usada em role-playing.
Dimensão (snowflake)	dim_localizacao	Cidade e região. Referencia dim_estado, que referencia dim_pais — hierarquia normalizada (snowflake).
Dimensão (snowflake)	dim_estado	Estados americanos. Pai de dim_localizacao, filho de dim_pais.
Dimensão (snowflake)	dim_pais	Países. Topo da hierarquia geográfica.
Dimensão	dim_genero	M / F com descrição padronizada (Masculino / Feminino).
Dimensão	dim_faixa_etaria	Faixas etárias (até 25, 26-35, 36-45, 46-55, 56-65, acima de 65).
Dimensão	dim_faixa_salarial	Faixas salariais (até 40k, 40-70k, 70-100k, 100-150k, acima de 150k).

4.3 Conceitos avançados aplicados

O enunciado exige aplicação de no mínimo 2 conceitos avançados. O projeto aplica 4:

- **Dimensão enriquecida:** a dim_tempo não armazena apenas a data, mas todos os atributos calendário relevantes (ano, semestre, trimestre, mês, nome do mês, dia, dia da semana ISO, nome do dia, flag de fim de semana). Isso permite slicing temporal complexo no Power BI sem cálculos adicionais.
- **Dimensão role-playing:** a mesma dim_tempo é referenciada duas vezes pela tabela fato (tempo_id_admissao e tempo_id_nascimento). Isso permite, por exemplo, cruzar “mês de admissão” com “mês de nascimento” sem duplicar a tabela calendário.
- **Snowflake:** a hierarquia geográfica foi normalizada em três tabelas relacionadas (dim_localizacao → dim_estado → dim_pais), reduzindo redundância e permitindo análise em qualquer nível da hierarquia.
- **Dimensão degenerada:** o identificador de negócio do funcionário (emp_id) é armazenado diretamente na fato, sem necessidade de dimensão própria. Funciona como “chave de evento” preservando rastreabilidade até o sistema de origem.

5. Arquitetura em camadas

A solução foi organizada em quatro schemas no PostgreSQL, com responsabilidades bem separadas:

- repositorio — camada de staging. Recebe o CSV bruto sem qualquer transformação, com todas as colunas como TEXT. Serve de fonte para o ETL e como histórico do dado original.
- dw — camada do Data Warehouse. Contém o modelo estrela com a fato e as sete dimensões, dados já tratados e tipados.
- datamart — camada semântica orientada ao Power BI. Contém views analíticas pré-agregadas e uma view “achatada” (vw_fato_rh) que serve de tabela fato no modelo do BI. Foram criadas quatro views: vw_fato_rh, vw_salario_por_estado, vw_admissoes_por_ano e vw_faixa_genero.
- security — camada de controle de acesso (entrega adicional, além do escopo do enunciado). Contém três views (vw_funcionario, vw_rh, vw_diretor) com diferentes níveis de exposição de dados sensíveis, vinculadas a três roles do PostgreSQL com GRANTS específicos.

6. Processo de ETL

O ETL foi implementado em SQL puro, em um único script versionável, partindo de repositorio.rh_raw e populando todas as tabelas de dw. As principais transformações documentadas são:

- Padronização de texto: aplicação de TRIM em todos os campos de texto e UPPER em códigos de estado para garantir consistência (ex.: " CA " e "ca" passam a ser "CA").
- Conversão de tipos: datas em formato "MM/DD/YYYY" convertidas via TO_DATE; campos numéricos armazenados como texto convertidos para NUMERIC.
- Limpeza de percentual: o campo last_hike_percent vinha como texto com símbolo de % (ex.: "21%"). Aplicou-se REPLACE para remover o símbolo, NULLIF para tratar string vazia e CAST para NUMERIC.
- Tratamento de duplicatas: a carga da dim_funcionario usa GROUP BY emp_id com agregação MIN nos campos descritivos, garantindo unicidade por chave de negócio.
- Tratamento de chaves geográficas compostas: a dim_localizacao usa a combinação (cidade, estado) como chave única, evitando que cidades homônimas em estados diferentes (ex.: Springfield em IL e MA) sejam tratadas como a mesma localização.
- Categorização (bucketização): salários e idades brutos são associados às faixas correspondentes via JOIN com BETWEEN nas dimensões de faixa.
- Tratamento de nulos e inválidos: registros sem emp_id, sem data de admissão ou sem salário são filtrados na carga da fato; campos opcionais usam COALESCE com valor default razoável.

O script de ETL é idempotente: inicia com DROP SCHEMA IF EXISTS CASCADE em todos os schemas, permitindo reexecução sem duplicação.

7. Data Mart

O schema datamart é a interface de consumo do Power BI. Decidiu-se entregar quatro views, ao invés do mínimo exigido de uma, para já oferecer agregações comuns prontas e diminuir a carga sobre o BI:

- **vw_fato_rh** — view achatada que junta a fato com todas as dimensões. Funciona como tabela fato no modelo do Power BI, com nomes de colunas em português e tipos corretos.
- **vw_salario_por_estado** — agrega por estado: contagem de funcionários, salário médio, mínimo, máximo e folha total.
- **vw_admissoes_por_ano** — agrega admissões por ano e trimestre, com salário médio de entrada.
- **vw_faixa_genero** — cruza faixa salarial com gênero, útil para análise de equidade.

8. Camada semântica e dashboard (Power BI)

O Power BI Desktop conecta-se ao PostgreSQL via conector nativo, importando as quatro views do schema datamart. A view **vw_fato_rh** é configurada como tabela fato; as demais entram como tabelas agregadas independentes.

8.1 Medidas DAX

Foram criadas 12 medidas DAX (mínimo exigido: 10):

#	KPI	Definição / Fórmula DAX
1	Total de Funcionários	COUNTROWS(vw_fato_rh)
2	Folha Salarial Total	SUM(vw_fato_rh[salario])
3	Salário Médio	AVERAGE(vw_fato_rh[salario])
4	Salário Mediano	MEDIAN(vw_fato_rh[salario])
5	Salário Máximo	MAX(vw_fato_rh[salario])
6	Idade Média	AVERAGE(vw_fato_rh[idade_anos])
7	Tempo Médio de Empresa	AVERAGE(vw_fato_rh[tempo_empresa_anos])
8	% Aumento Médio	AVERAGE(vw_fato_rh[percentual_ultimo_aumento])
9	Crescimento YoY %	Comparação ano atual vs anterior em admissões
10	% do Total	DIVIDE([Total Funcionarios], total geral)
11	Ranking por Folha	RANKX por Folha Total entre estados

#	KPI	Definição / Fórmula DAX
12	% Mulheres	Participação feminina no quadro

8.2 Estrutura do dashboard

O dashboard foi organizado em cinco páginas, com navegação por sidebar:

- Visão Geral — cards com os 5 KPIs principais e gráfico de pizza (donut) de participação por gênero.
- Geografia — cards de destaque, gráfico de barras com os Top 10 estados por folha total, tabela analítica e slicer por região.
- Demografia — matriz cruzando faixa etária × gênero (salário médio), gráfico em funil por faixa salarial e slicer por gênero.
- Evolução Temporal — gráfico de linha/área com admissões por ano, matriz ano × trimestre e slicers temporais.
- Sobre o Projeto — botões com informações do grupo, fonte de dados e diagrama do modelo.

Todas as visualizações obrigatórias do enunciado estão contempladas: gráfico de linha temporal, gráfico de barras, gráfico de participação (donut), tabelas/matrizes e cards com KPIs.

9. Principais decisões técnicas

- Optar por snowflake parcial apenas na hierarquia geográfica, deixando as demais dimensões em estrela pura. Snowflake total complicaria desnecessariamente o modelo sem ganho de espaço relevante.
- Manter dimensões de faixa (etária e salarial) como tabelas pré-categorizadas, ao invés de calcular as faixas via DAX no Power BI. Isso simplifica o relatório e centraliza a regra de negócio no banco.
- Adotar emp_id como dimensão degenerada na fato, evitando criar uma dimensão de “evento de contratação” que teria apenas um atributo.
- Criar uma view “achatada” no data mart (vw_fato_rh) em vez de expor o modelo estrela diretamente ao Power BI. Isso reduz o número de relacionamentos no BI, melhora performance e simplifica DAX.
- Implementar a camada de segurança com roles e views específicas, mesmo não sendo exigido pelo enunciado, como diferencial de organização profissional.
- Tornar o script de ETL idempotente (DROP SCHEMA IF EXISTS no início), facilitando demonstração em ambiente acadêmico onde o banco pode ser recarregado várias vezes.

10. Desafios enfrentados

- Volume de dados: o CSV de 265 MB com 1 milhão de linhas exigiu atenção à performance da carga. Foram criados índices nas chaves estrangeiras da fato após a carga.
- Inconsistência de chaves geográficas: cidades com o mesmo nome em estados diferentes (Springfield em IL, MA, MO etc.) inicialmente causavam joins incorretos. Resolvido com chave composta (cidade, estado) na dim_localizacao.
- Campos textuais que pareciam numéricos: o percentual de aumento ("21%") e várias outras colunas vieram do CSV como texto e exigiram REPLACE + NULLIF + CAST.
- Role-playing no Power BI: por padrão, o Power BI não permite duas tabelas com a mesma chave relacionando-se à mesma tabela. Foi necessário desativar relacionamentos automáticos no banco e usar USERELATIONSHIP em DAX para alternar entre as datas (admissão / nascimento).
- Caminho do arquivo no COPY: o caminho absoluto inicial dependia do sistema de arquivos do servidor PostgreSQL. Substituído pela orientação de usar \copy do psql cliente, mais portátil entre máquinas dos integrantes.

11. Insights encontrados

A análise no Power BI sobre o dataset tratado revelou padrões interessantes:

- Concentração geográfica: a folha salarial total se concentra fortemente em poucos estados (CA, NY, TX), mas isso reflete principalmente o volume de funcionários — o salário médio é mais equilibrado entre regiões.
- Distribuição etária: a faixa de 36 a 45 anos é a mais populosa, mas as faixas mais experientes (46-55 e 56-65) concentram os maiores salários médios, confirmando relação tempo-de-carreira × remuneração.
- Participação de gênero: a base apresenta distribuição razoavelmente equilibrada entre homens e mulheres no quadro geral, mas com leve diferença salarial média favorável a um dos grupos quando se controla por faixa etária — sinal para investigação mais profunda em projetos reais.
- Sazonalidade de admissões: o primeiro trimestre concentra mais admissões do que os demais, comportamento típico de empresas com planejamento anual de headcount.
- Tempo de empresa: a média de tempo de empresa indica retenção saudável, mas com cauda longa de funcionários de longo prazo (>20 anos).

12. Conclusão

O projeto entrega um Data Warehouse completo, funcional e aderente a todos os requisitos obrigatórios do enunciado, com diferenciais que excedem o mínimo: 7 dimensões (mínimo 6), 4 conceitos avançados aplicados (mínimo 2), 4 views no data mart (mínimo 1), 12 KPIs DAX (mínimo 10) e camada extra de segurança com 3 perfis de acesso. A

separação clara em quatro schemas (repositorio, dw, datamart, security) e o script idempotente tornam a solução reprodutível e profissional. A escolha do tema de RH com dados reais de Kaggle permitiu explorar problemas concretos de tratamento (datas em texto, percentuais como string, cidades homônimas) e gerar insights de negócio efetivos sobre demografia, geografia e remuneração.